



# PREDIÇÃO DA ALTURA DE QUEDA DA USINA DE JIRAU UTILIZANDO REDES NEURAIS ARTIFICIAIS RECORRENTES LSTM

Silva, D.F.C.<sup>1</sup>, Galvão Filho, A.R.<sup>1,2</sup>, Carvalho, R.V.<sup>1,2</sup>, Coelho, C.J.<sup>1,2</sup>

<sup>1</sup> Laboratório de Computação Científica - Escola de Ciências Exatas e da Computação

Pontifícia Universidade Católica de Goiás

Goiânia-Goiás-Brasil

<sup>2</sup> Mestrado em Engenharia de Produção e Sistemas

Pontifícia Universidade Católica de Goiás

Goiânia-Goiás-Brasil

**RESUMO:** Um sistema ciberfísico (*Cyber Physical Systems*, CPS) são integrações de computação, rede e processos físicos. Um CPS possibilita operações em níveis virtuais e reais, interagindo e controlando dispositivos físicos, sensoriando e atuando no mundo real. Um dos principais conceitos associados ao CPS é o Gêmeo Digital (GD), que modela de modo computacional um sistema físico, explorando sincronizações em tempo real dos dados obtidos do sistema. Uma modelagem amplamente utilizada em sistemas com as características de um GD são as redes neurais artificiais (RNA) recorrentes. Tais redes proporcionam ao GD obter dinâmicas preditivas do sistemas possibilitando maior assertividade nas tomadas de ações no sistema. Neste contexto, este trabalho propõe um modelo de RNA do tipo *Long Short Term Memory* (LSTM) para predição de queda do rio que abastece a usina hidrelétrica de Jirau. O modelo resultou em uma predição com erro quadrático médio de 0.0479 para um horizonte de tempo predito de 291 dias.

**Palavras-chave:** Gêmeo Digital, Usina Hidrelétrica, Redes Neurais Artificiais.

**ABSTRACT:** Cyberphysical system (CPS) are integrations of computing, networking, and physical processes. A CPS enables real and multi-level operations, physical device interaction and control, real-world detection and actuation. One concepts associated with CPS is Digital Twin (GD), which computationally models a physical system, exploring real-time synchronization of data obtained from a system. One modeling widely used in systems with the characteristics of a GD is artificial neural networks (RNA). These networks provide GD with predictive system dynamics that enable greater assertiveness in system actions. In this context, this work offers a Long Short Term Memory (LSTM) RNA model to predict river fall of Jirau hydroelectric plant. Model resulted in a prediction with mean square error of 0.0479 for a predicted time horizon of 291 days.

**Keywords:** Digital Twin, Hydroelectric plant, Artificial Neural Network.

## 1. Introdução

Nos últimos anos, o cenário industrial é desafiado mundialmente com o crescimento e avanços nas tecnologias digitais que permitem a integração de componentes inteligentes interconectados em seu sistema. Esta é a base da chamada Indústria 4.0 [1]. Embora seja uma tendência recente, a Indústria 4.0 tem sido amplamente discutida e suas principais tecnologias foram identificadas [2], entre as quais Sistemas Ciber-Físicos (Cyber-Physical Systems, CPS) têm sido propostos como sistemas inteligentes que operam em níveis virtuais e físicos, interagindo e controlando dispositivos físicos, sensoriando e atuando no mundo real [3,4].

O Gêmeo Digital (GD) é um dos principais conceitos associados aos CPS [5,6]. Ele pode ser definido como um modelo virtual e computadorizado de um sistema físico que pode ser usado em simulações de diversas finalidades, explorando sincronizações em tempo real dos dados detectados vindos do campo [7,8]. Além de gerar dinâmicas tais dinâmicas em tempo real, um dos principais papéis de um GD é proporcionar a capacidade preditiva dos cenários simulados para auxílio à tomada de decisão [9,10]. Um dos principais modelos capazes de descrever de modo preditivo as dinâmicas dos processos envolvendo modelos GD são as redes neurais artificiais (RNA).

Diversos modelos de RNA são usados para descrever dinâmicas no contexto de GD, tais como em um modelo de fábrica inteligente [11], no prognóstico e gerenciamento da saúde de equipamentos complexos [12], na modelagem e uso de uma máquina CNC [13], e diversos outros [14,15,16].

As usinas hidrelétricas (UHE) modernas são plantas de geração com automações complexas e operam em ecossistemas interligados a um grande conjunto de processos e variáveis dinâmicas internas e externas à planta. Variáveis simples como a queda do rio, geram tomada de ação de complexas para a gestão de geração de energia elétrica por múltiplas máquinas geradoras. Um exemplo então de uso de um modelo GD seria proporcionar a capacidade preditiva da dinâmica de queda tomada de ação mais assertiva em uma UHEs.

Neste contexto, este trabalho propôs um modelo de RNA recorrente para a previsão temporal da dinâmica de queda de uma UHE para inserção em um GD. Como estudo de caso foram utilizados dados reais da planta física da UHE Jirau para validação o modelo.

## 2. Materiais e Métodos

### 2.1. Redes Neurais Artificiais Recorrentes

Redes neurais artificiais (RNA) são modelos computacionais inspirados no sistema nervoso de seres vivos, possibilitando a capacidade de aquisição e manutenção do conhecimento [17]. As RNAs podem ser definidas como um conjunto de unidades de processamento, caracterizadas por neurônios artificiais, que são interligados por um grande número de interconexões [17]. Tais conexões representam são ponderadas por um determinado peso, representando as sinapses geradas pelos neurônios. O processo de aprendizagem ocorre pela apresentação de um conjunto de exemplos fornecidos à rede, e por meio das informações contidas nestes exemplos são realizadas mudanças nos valores dos pesos sinápticos. Portanto, o processo de ajuste dos pesos sinápticos visa sintonizar a rede para que suas respostas estejam de acordo com o esperado [18].

Uma aplicação amplamente explorada recentemente são as RNA's capazes de gerar previsões de séries temporais [19]. Estas redes inserem a transição temporal como um requisito para a aprendizagem, ou seja, a boa performance da rede está associada tanto aos exemplos dados como na ordem em que eles são fornecidos. Tais redes são conhecidas como redes neurais recorrentes (RNN) [19]. As RNN possuem conexões de retroalimentação nas conexões sinápticas, que possibilita a inserção da saída de volta ao neurônio. Esta inserção permite que a rede altere os pesos sinápticos dos neurônios referentes ao tempo anterior [20]. Dessa forma é possível gerar uma espécie de memória capaz de armazenar informações por longos períodos de tempo ao processar uma sequência [21].

A rede *Long Short Term Memory* (LSTM) é um tipo de RNN bastante utilizada para previsão de séries temporais em aplicações de gestão em energia elétrica. Como por exemplo em [22] que faz previsões de curto prazo de energia elétrica das residências particulares utilizando a rede LSTM, em [23] mostra-se uma comparação da combinação da rede LSTM e a rede *Autoencoder* com uma MLP padrão para previsão de energia solar em [24] é apresentado uma nova metodologia de previsão de energia elétrica com base na arquitetura da LSTM, em [25] é proposto a previsão da potência de saída dos sistemas fotovoltaicos utilizando a rede LSTM, em [26] é mostrado o uso de uma LSTM para resolver o problema de previsão de carga elétrica de uma rede elétrica inteligente,

diversos outros trabalhos. Portanto este trabalho propõe o estudo de uma rede LSTM para a predição de uma série temporal da queda da UHE Jirau.

A rede LSTM proposta é do tipo regressão, e possui uma camada de sequência de entrada, uma camada LSTM com um tamanho oculto de 200, que é a quantidade de informações lembradas entre cada etapa de tempo, uma camada totalmente conectada e uma camada de saída da regressão. O treinamento foi configurado com 250 épocas, e para impedir a explosão do gradiente, o limite do gradiente foi definido como 1, e inicia com uma taxa de aprendizado de 0.005 reduzindo após 125 épocas, multiplicando por um fator de 0.2, terminando com uma taxa de 0.001.

## **2.2. Estudo de caso UHE Jirau**

A série temporal utilizada neste trabalho foram dados disponibilizados de queda bruta da usina hidrelétrica de Jirau. Ao analisar os dados, foi verificada a presença de valores nulos, provenientes à erros de leitura. Foi feito um pré-processamento dos dados para a remoção dos valores nulos e normalização.

Foram destinados 80% dos dados para o treinamento, correspondendo a 28005 leituras no decorrer de 11666 dias. Os 20% dos dados restantes foram destinados para teste, correspondendo a 7002 leituras no decorrer de 291 dias. Vale ressaltar que tanto a divisão dos dados entre treinamento e teste quanto a arquitetura de rede utilizada foram escolhidas empiricamente. Tal escolha foi baseada de acordo com a literatura e em testes feitos com diferentes configurações.

## **2.3. Avaliação dos resultados**

A avaliação do modelo proposto será dividida em duas etapas: A primeira consiste em gerar predições dos dados de teste com a rede treinada somente com os dados de treinamento. A segunda etapa consiste em atualizar os pesos da rede de acordo com os novos valores de referência obtidos na predição dos dados de teste.


A capacidade preditiva do modelo proposto será calculada pela raiz quadrada do erro quadrático médio (Root Mean Square Error, RMSE) como mostra a equação (1):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}, \quad (1)$$

onde  $y_i$  e  $\hat{y}_i$  são os valores de referência e os preditos, e  $N$  é a quantidade de valores de teste.

### 3. Resultados e Discussão


A figura 1 apresenta os resultados obtidos na primeira etapa. É possível observar a série temporal das medidas de queda bruta, medidas de hora em hora durante 291 dias. Verifica-se que a predição feita utilizando a rede treinada apenas com os dados de treinamento não se aproxima dos dados de referência. Tal comportamento é corroborado com o alto RMSE, que resultou em 3,5509.




**Figura 1:** Predição do experimento 1

Já a figura 2 mostra os resultados obtidos na segunda etapa da avaliação. Nota-se que as predições realizadas pelo modelo proposto, aparecem próximas dos valores de referência, que pode ser confirmado com RMSE resultante de 0,0794. Esta melhora é justificada graças à atualização dos pesos das redes baseadas nas predições sequenciais feitas com os dados de teste.

Uma segunda maneira de analisar os resultados da segunda etapa é apresentada na figura 3. Observa-se todo horizonte temporal dos dados medidos juntamente com os valores preditos pelo modelo. Mais uma vez verifica-se a assertividade da predição, corroborando com dinâmica real de queda. Vale ressaltar que os resultados obtidos por este trabalho mostram a viabilidade para o uso na planta física real.



**Figura 2:** Predição do experimento 2



**Figura 3:** Predição do experimento 2 após os dados observados

#### 4. Conclusão

As redes neurais artificiais oferecem a capacidade preditiva para a modelagem do gêmeo digital. As redes LSTM mais especificamente conseguem associar a capacidade preditiva temporal, fornecendo uma informação futura para auxílio a possíveis tomadas de ação de uma determinada dinâmica. Neste artigo, explorou-se o uso de uma RNA do tipo LSTM para predição da dinâmica da queda do rio da usina hidrelétrica de Jirau. Como resultado, constatou-se que a rede proposta gerou a predição de 291 dias com um erro de 0,0479. A arquitetura da rede proposta neste trabalho foi relativamente simples para fins de validação da modelagem utilizada. Em trabalhos futuros, pretende-se explorar outras arquiteturas mais complexas, validando outros cenários com novos dados,

variando a arquitetura e o horizonte de tempo. Espera-se nesse caso obter um estudo da robustez da rede quanto às variações da entrada de dados

## **5. Agradecimentos**

Os autores agradecem à Energia Sustentável do Brasil pelo apoio para realização deste estudo, contrato Jirau 064/2018, ANEEL PD-06631-0007/2018.

## **6. Referências Bibliográficas**

1. Lee, J., Baghrei B., Kao, H.-A.: A cyber-physical systems architecture for industry 4.0-based manufacturing systems. *Manufacturing letters*, Elsevier, v. 3, p. 18–23, 2015.
2. Brettel, M. et al.: How virtualization, decentralization and network building change the manufacturing landscape: An industry 4.0 perspective. *International journal of mechanical, industrial science and engineering*, v. 8, n. 1, p. 37–44, 2014.
3. Lee, E. A.: Cyber physical systems: Design challenges. In: IEEE. 2008 11th IEEE International Symposium on Object and Component-Oriented Real-Time Distributed Computing (ISORC). [S.l.], 2008. p. 363–369.
4. Baheti, R.; Gill, H.: Cyber-physical systems: The impact of control technology, IEEE Control Systems Society New York, v. 12, n. 1, p. 161–166, 2011.
5. Reifsnider, K., Majumdar, P.: Multiphysics stimulated simulation digital twin methods for fleet management. In: 54th AIAA/ASME/ASCE/AHS/ASC Structures, Structural Dynamics, and Materials Conference. [S.l.: s.n.], 2013. p. 1578.
6. Schluse, M., Rossmann, J.: From simulation to experimentable digital twins: Simulation-based development and operation of complex technical systems. In: IEEE. 2016 IEEE International Symposium on Systems Engineering (ISSE). [S.l.], 2016. p. 1–6.
7. Rosen, R. et al.: About the importance of autonomy and digital twins for the future of manufacturing. *IFAC-PapersOnLine*, Elsevier, v. 48, n. 3, p. 567–572, 2015.
8. Grieves, M., Vickers, J.: Digital twin: Mitigating unpredictable, undesirable emergent behavior in complex systems. In: *Transdisciplinary perspectives on complex systems*. [S.l.]: Springer, 2017. p. 85–113.
9. Lee, J., Bagheri, B., Kao, H.-A.: A cyber-physical systems architecture for industry 4.0-based manufacturing systems. *Manufacturing letters*, Elsevier, v. 3, p. 18–23, 2015.
10. Canedo, A.: Industrial iot lifecycle via digital twins. In: ACM. Proceedings of the Eleventh IEEE/ACM/IFIP International Conference on Hardware/Software Codesign and System Synthesis. [S.l.], 2016. p. 29.
11. Tao, Fei, Zhang, Meng.: Digital twin shop-floor: a new shop-floor paradigm towards smart manufacturing. *Ieee Access*, v. 5, p. 20418-20427, 2017.
12. Tao, Fei et al.: Digital twin driven prognostics and health management for complex equipment. *CIRP Annals*, v. 67, n. 1, p. 169-172, 2018.

13. Luo, Weichao et al.: Digital twin for CNC machine tool: modeling and using strategy. *Journal of Ambient Intelligence and Humanized Computing*, v. 10, n. 3, p. 1129-1140, 2019.
14. Alam, M. K., Saddik E., Abdulmotaleb.: C2PS: A digital twin architecture reference model for the cloud-based cyber-physical systems. *IEEE Access*, v. 5, p. 2050-2062, 2017.
15. Knapp, G. L. et al.: Building blocks for a digital twin of additive manufacturing. *Acta Materialia*, v. 135, p. 390-399, 2017.
16. Kritzinger, Werner et al.: Digital Twin in manufacturing: A categorical literature review and classification. *IFAC-PapersOnLine*, v. 51, n. 11, p. 1016-1022, 2018.
17. Silva, I. N., Spatti D. H., Flauzino R.A.: *Redes Neurais Artificiais Para Engenharia e Ciências Aplicadas. Fundamentos Teóricos e Aspectos Práticos*. 2<sup>a</sup> ed. São Paulo: Editora Artliber LTDA, 2016.
18. Carvalho A. P. B., Ludemir T. B., Leon A. C. P. *Redes Neurais Artificiais: teoria e aplicações*, Livros Técnicos e Científicos Editora S/A, 2000.
19. Lazzarotto, et al.: MELHORIA NA PREVISÃO DA SÉRIE TEMPORAL DE INSTRUMENTOS DE MONITORAMENTO DE BARRAGEM VIA COMBINAÇÃO DE MÉTODOS. *Cadernos do IME - Série Estatística*. 38. 10.12957/cadest.2015.18510, 2015.
20. Segatto E.C., Coury D.V.: Redes neurais artificiais recorrentes aplicadas na correção de sinais distorcidos pela saturação de transformadores de corrente. *Sba Controle & Automação*. Acesso em 29 de outubro de 2019; 17(4). Disponível em: [http://www.scielo.br/scielo.php?script=sci\\_arttext&pid=S0103-17592006000400004&lng=en&nrm=iso](http://www.scielo.br/scielo.php?script=sci_arttext&pid=S0103-17592006000400004&lng=en&nrm=iso)
21. Ronaldo C.D.: ESTUDO DA APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA PREDIÇÃO DE SÉRIES TEMPORAIS FINANCEIRAS. Dissertação de mestrado. Bauru: UNESP (2018).
22. Kong, Weicong et al.: Short-term residential load forecasting based on LSTM recurrent neural network. *IEEE Transactions on Smart Grid*, v. 10, n. 1, p. 841-851, 2017.
23. Gensler, André et al.: Deep Learning for solar power forecasting—An approach using AutoEncoder and LSTM Neural Networks. In: 2016 IEEE international conference on systems, man, and cybernetics (SMC). IEEE, 2016. p. 002858-002865.
24. Marino D. L., Amarasinghe, K., Manic, M.: Building energy load forecasting using deep neural networks. In: IECON 2016-42nd Annual Conference of the IEEE Industrial Electronics Society. IEEE, 2016. p. 7046-7051.
25. Abdel-nasser M., Mahmoud K.: Accurate photovoltaic power forecasting models using deep LSTM-RNN. *Neural Computing and Applications*, v. 31, n. 7, p. 2727-2740, 2019.
26. Zheng, Jian et al.: Electric load forecasting in smart grids using long-short-term-memory based recurrent neural network. In: 2017 51st Annual Conference on Information Sciences and Systems (CISS). IEEE, 2017. p. 1-6.